总体：

首先使用共享参数的MLP层提取输入点云每个点的特征。然后使用四个编码和解码层来学习每个点的特征。最后，使用三个全连接层和一个Dropout层来预测每个点的语义标签

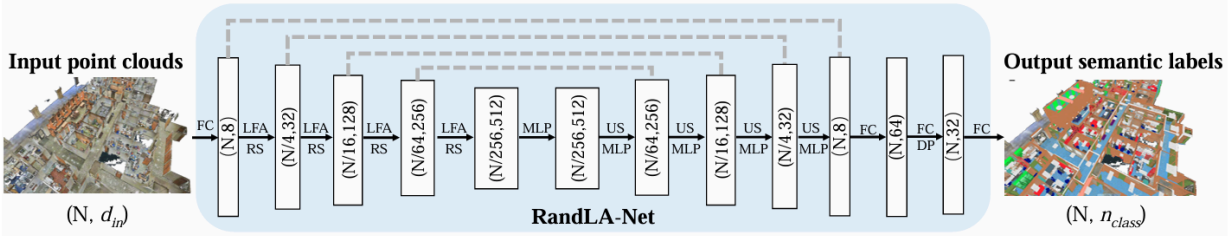

Figure 7. The detailed architecture of our RandLA-Net. (N, D) represents the number of points and feature dimension respectively. FC: Fully Connected layer, LFA: Local Feature Aggregation, RS: Random Sampling, MLP: shared Multi-Layer Perceptron, US: Up-sampling, DP: Dropout.

输入：

网络输入

输入为$N \times d_{in}$的大规模点云。N为点的数量；d_{in}为每个输入点的特征维数。

编码层：

编码层

RandLA-Net中使用了四个编码层，以逐步减小点云的大小并增加每点特征维数。每个编码层由局部特征聚合模块和随机采样组成。

下采样保留25%的点云：

$$\left(N \rightarrow \frac{N}{4} \rightarrow \frac{N}{16} \rightarrow \frac{N}{64} \rightarrow \frac{N}{256}\right)$$

同时，每层逐点特征维数是逐渐增加的，以保留更多信息：

$$(8 \rightarrow 32 \rightarrow 128 \rightarrow 256 \rightarrow 512)$$

解码层：

在上述编码层之后使用四个解码层。对于解码器中的每一层，我们首先使用KNN算法为每个查询点（编码阶段对应的四倍于解码层输入点的点集）找到输入点中的一个最近邻点，然后通过最近邻插值对点特征集进行上采样（使查询点的特征等于距离它最近的输入点的特征）。接下来，通过跳跃连接将上采样特征与编码层生成的中间特征拼接起来，然后将共享参数的MLP应用于拼接的特征。

最终语义预测：

每个点的最终语义标签通过三个共享参数的全连接层和Dropout层获得。

$$(N, 64) \rightarrow (N, 32) \rightarrow (N, n_{\text{class}})$$

其中n_{class}是类别数。

动机

前人研究的问题：

PointNet提出了处理点云的方法，但是大部分用于小点云，比如4k点于1*1m,并且不能直接扩展到没有块分区等预处理步骤的大规模点云数据中

造成这种限制的原因可以概括为以下三种：

> 1.这些网络中常用的点采样方法要么是计算成本高，要么是内存效率低。例如，广泛使用的最远点采样*需要超过200秒才能对100万个点中的10%进行采样
> 2.大多数现有的局部特征学习器通常依赖于计算昂贵的核化或图构造（类似于GNN），因此无法处理大量的点
> 3.对于通常由数百个对象组成的大规模点云，由于接收域的大小有限，现有的局部特征学习器要么就是无法捕获复杂结构，要么就是效率低下

RandLA的改进：

随机抽样具有显著的计算和内存效率，但可能会偶然丢弃关键特征。为了克服这个问题，作者引入了一种新的局部特征聚合模块，逐步增加每个3D点的接受域，从而有效地保留几何细节。

难点：

目标：直接处理大规模的三维点云，而不需要任何预处理/后处理步骤，如体素化（voxelization）、块划分或图构造

1.建立一种内存和计算效率高的采样方法，逐步向下采样大规模点云，以适应当前GPU的限制
2.建立一个有效的局部特征学习器，逐步增加接受域的大小，以保持复杂的几何结构

Methods：

采样：

首先点云数据太大了，肯定是要进行下采样的。传统的采样方法如下：

A. 启发式

Farthest Point Sampling (FPS)：为了从一个含有N个点的大规模点云P种抽样K个点，FPS返回了对一个度量空间的重新排序 $\{p_1 \ldots p_k \ldots p_K\}$ ，例如每一个 p_k 是从第一组 $k-1$ 个点选择来的。FPS被广泛应用于小型点云的语义分割任务中。尽管它很好地覆盖了整个点集，它的计算复杂度是 $O(N^2)$ 。对于一个大规模点云（ $N \sim 10^6$ ），FPS在一个单独的GPU上进行处理耗费大约200s，这说明FPS并不适合大规模点云。
Inverse Density Importance Sampling (IDIS)：为了从一个含有N个点的大规模点云P种抽样K个点，IDIS将所有N个点根据每个点的密集度进行重新排序，然后最密集的K个点将被选中，它的计算复杂度是 $O(N)$ ，经验上来说，处理 10^6 个点将耗费10s，与FPS相比，IDIS效率更高，但对异常值也更敏感。然而，在实时系统中使用它仍然太慢。
Random Sampling (RS)：RS随机抽样从原始N个点中均匀选取K个点，它的计算复杂度是 $O(1)$ ，与输入点数的总数无关，与FPS和IDIS相比，无论输入点云的规模如何，随机采样的计算效率最高。处理 10^6 个点只需要0.004秒。

B．学习式

Generator-based Sampling (GS)：GS通过学习生成一个小点集来近似表示原始的大点集。然而，在推理阶段，为了将生成的子集与原始集进行匹配，通常会使用FPS，导致额外的计算。在实验中，采样 10^6 个点中的10%需要1200秒。

Continuous Relaxation based Sampling (CRS)：CRS方法使用重参数化(reparameterization)技巧将采样操作放到连续域进行端到端训练。具体来说，每个采样点都是基于整个点云的加权和来学习的。当用一次矩阵乘法同时采样所有新点时，会产生一个较大的权矩阵，导致难以承受的存储成本。例如，估计要对 10^6 个点中的10%进行抽样，需要占用超过300gb的内存。

Policy Gradient based Sampling (PGS)：PGS将抽样操作表述为马尔可夫决策过程。它顺序地学习一个概率分布来采样点。但是，当点云较大时，由于探索空间非常大，学习概率方差很大。例如，采样 10^6 个点的10%，探索空间为 $c_{10^5}^{10^6}$ ，不太可能学习到有效的采样策略。经验发现，如果PGS用于大的点云，网络很难收敛。

随机采样最适合处理大规模的点云，但是随机采样会导致许多的点特征被丢弃，所以设计局部特征聚合（Local Feature Aggregation）模块

局部特征融合：

局部特征聚合(LFA)模块是一个残差模块，由三个神经单元组成

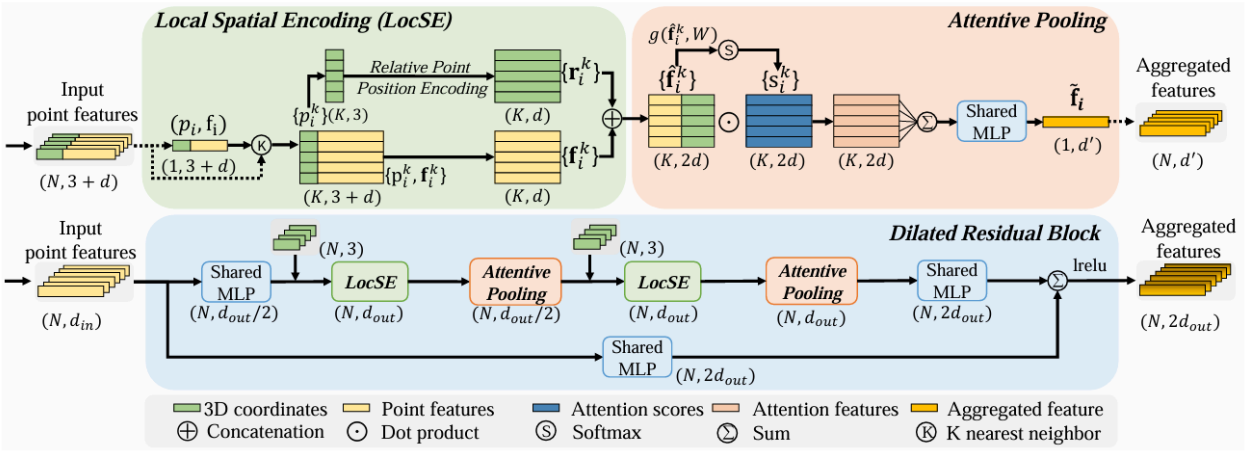

由于大规模的点云将会被下采样，因此希望显著地增加每个点的感受野，这样即使一些点被删除，输入点云的几何细节也更有可能被保留。为了达到这个目的，RandLA-Net将两个LocSE和altentive pooling堆叠起来：

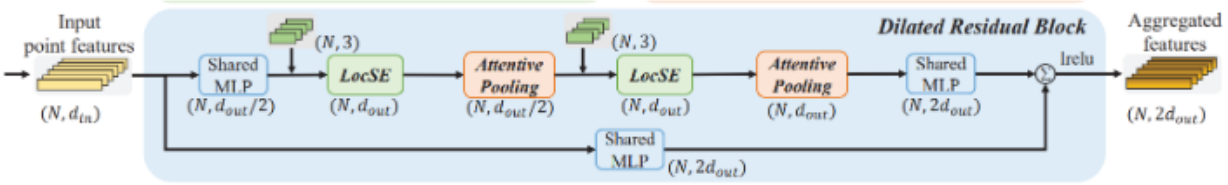

1local spatial encoding (LocSE)

局部几何图案

输出中心点pi的局部几何结构

算法：

Finding Neighbouring Points： 对于第i个点，首先采用简单的K-最近邻(KNN)算法根据点方向的欧氏距离收集其邻近点以提高效率。
Relative Point Position Encoding： 对于每一组以 p_i 为中心的最近K个点 $\{p_i^1 \dots p_i^k \dots p_i^K\}$ ，显式地将相对点位置编码如下

$$\mathbf{r}_i^k = MLP\left(p_i \oplus p_i^k \oplus (p_i - p_i^k) \oplus ||p_i - p_i^k||\right)$$

其中 p_i 和 p_i^k 是每个点的x-y-z坐标， $\oplus$ 代表拼接操作， $||\cdot||$ 计算相邻点和中心点之间的欧氏距离，这意味着 r_i^k 是从冗余点位置编码。有趣的是，这往往有助于网络学习局部特征，并取得良好性能。
Point Feature Augmentation： 对于每个相邻点 p_i^k ，将编码后的相对点位置 r_i^k 与其对应的点特征 f_i^k 连接，得到增广的特征向量 $\hat{f}_i^k$ 。

2attentive pooling

聚合邻近点特征的集合

注意机制来自动学习重要的局部特征

总的来说，给定输入点云P，对于第i个点Pi，LocSE和Attentive Pooling单元学习聚合其K个最近点的几何模式和特征，并最终生成一个信息特征向量fi

3dilated residual block

由于大的点云将被大幅向下采样，因此需要显著增加每个点的接受域，这样输入点云的几何细节更有可能被保留，即使一些点被删除
(参考ResNet的堆叠)
理论上讲，堆叠的units越多，这个block就越强大，因为它的范围会变得越来越大。然而，更多的units不可避免地会牺牲整体的计算效率，并且整个网络可能过拟合。在RandLA-Net中，作者简单地将两组LocSE和Attentive Pooling堆叠起来作为标准residual block

综上：

叠加多个局部特征聚合模块和随机采样层来实现RandLA-Net
优化器：Adam，lr=0.01，每个epoch后降低5%，最接近的点数k=16，从每个点云当中抽取固定的约10^5的点输入
测试过程中，整个原始点云被输入到我们的网络中，以推断每个点的语义，而不需要进行几何或块划分等预处理/后处理
平台：RTX2080Ti

实验：

关注在Semantic3D上，
Semantic3D有15和15个点云用于训练和测试。每张图约有1亿点，分布在160*240*30m的范围内，8个类
在这里，用3D坐标和颜色信息训练测试